

关键词清洗与标准化工具

用户手册

v2.4

项目	说明
适用对象	万方数据库文献计量学研究者
运行环境	Windows / macOS / Linux
技术栈	Python 3.8+, tkinter GUI

目录

1 工具概述

2 安装与启动

2.1 安装依赖

2.2 启动方式

3 完整操作流程

3.1 六步流水线总览

3.2 Step 1-3: 数据解析与清洗

3.3 Step 4: 变体检测（核心）

3.4 Step 5: 人工审核

3.5 Step 6: 导出标准化结果

4 GUI审核界面详解

4.1 工具栏按钮功能

4.2 审核操作说明

4.3 策略来源标识

5 全局映射表功能

5.1 使用场景

5.2 操作流程

5.3 增量积累机制

6 迭代优化循环

6.1 Error Analysis

6.2 规则修正流程

7 输出文件详解

8 命令行使用

9 常见问题

1 工具概述

关键词清洗与标准化工具用于处理万方数据库导出的文献记录，自动识别并合并同义关键词变体，减少人工整理工作量，为后续共现分析和网络分析提供标准化的关键词数据。

工具解决的核心问题：同一概念在文献中常以不同写法出现，例如"循证护理"与"循证护理学"、"生活质量"与"生命质量"。如果不加合并，这些变体会被当作不同关键词，导致频次分散、共现网络碎片化。

工具采用五策略级联检测机制，配合语义分歧检测防止误合并，并通过GUI审核界面让人工把关最终结果。v2.4新增全局映射表功能，支持多期刊批量处理时复用已审核结果。

1.1 核心特性

特性	说明
自动变体检测	五策略级联：归一化匹配、前后缀匹配、Jaccard相似度、编辑距离、全局映射预合并
语义分歧防护	医学关键字符集+内容词对黑名单，防止"护理管理"与"护理伦理"等误合并
GUI审核界面	逐群组审核，支持确认/保留/选择性合并，审核进度自动保存
全局映射表	跨期刊复用已审核映射，避免重复劳动
迭代优化	部分审核后运行Error Analysis，根据FP率修正规则，循环优化
策略溯源	每对匹配标注来源策略，便于定位问题规则

2 安装与启动

2.1 安装依赖

首次使用前需安装Python依赖包。两种方式：

方式一：GUI内置安装

启动GUI后点击工具栏"Install Deps"按钮，自动安装所需包。

方式二：命令行安装

```
pip install -r requirements.txt
```

依赖包列表：

```
lxml>=4.9.0 # XML解析 counter # 计数器 (Python内置)
```

2.2 启动方式

Windows： 双击 start.bat

macOS： 双击 start.command（首次需在终端执行 `chmod +x start.command`）

命令行：

```
python keyword_cleaner.py -i 数据目录/ -o 输出目录/
```

仅启动审核GUI（已有分析结果）：

```
python gui_review.py 输出目录/
```

3 完整操作流程

3.1 六步流水线总览

工具采用六步流水线设计，每一步的输出是下一步的输入：

步骤	名称	说明
Step 1	解析万方XML	读取XML文件，提取文献记录
Step 2	清洗关键词	统一格式、去特殊字符、全角转半角
Step 3	导出原始数据	输出原始关键词列表和频次表
Step 4	变体检测	五策略级联检测同义变体
Step 5	人工审核	GUI逐群组审核，确认或拒绝合并
Step 6	导出标准化结果	应用映射表，输出标准化关键词

3.2 Step 1-3：数据解析与清洗

在GUI中点击"Run Analysis"按钮，选择输入文件或文件夹，工具自动完成Step 1-3：

Step 1 - 解析万方XML：自动检测文件编码和格式（支持XML和无扩展名文件），提取每条文献的标题、作者、关键词等字段。

Step 2 - 清洗关键词：对每条关键词执行：去除首尾空格、全角转半角、统一大小写、去除特殊符号（保留连字符和&符号）。

Step 3 - 导出原始数据：生成原始关键词列表和频次统计表（详见第7节）。

3.3 Step 4：变体检测（核心）

变体检测采用五策略级联，按优先级依次执行：

策略	名称	说明	优先级
策略0	全局映射预合并	已审核确认的同义词直接合并，无需再次审核	最高
策略1	归一化精确匹配	去除空格/标点后完全相同的词	高
策略2	严格前后缀匹配	短词是长词的前缀，且多出部分是语法后缀（学/法）	高
策略3	Jaccard相似度	字符级相似度 ≥ 0.85 ，且共享核心子串	中
策略4	编辑距离	少量字符差异，经语义分歧检测通过	中
策略5	共现邻居否决	邻居完全不重叠的配对被拆散（仅否决，不增强）	辅助

语义分歧检测是防止误合并的关键机制。当策略2-4检测到字面相似的词对时，会进一步检查差异字符是否属于"医学关键字符集"（如癌/炎/期/率/入/植等）。如果差异字符承载核心语义，则拒绝合并。例如：

"依从性" vs "依从率"：差异字符"率"在关键字符集中，拒绝合并

"导管插入术" vs "导管植入术"：差异字符"入/植"在关键字符集中，拒绝合并

"循证护理" vs "循证护理学": 差异部分"学"是语法后缀, 允许合并

3.4 Step 5: 人工审核

变体检测完成后, GUI自动加载待审核群组。每个群组包含2个或更多疑似同义关键词, 用户逐组确认或拒绝。详见第4节。

3.5 Step 6: 导出标准化结果

审核完成后, 点击"**Apply** & **Export Final**"按钮, 工具将映射表应用到原始数据, 生成标准化关键词列表。详见第7节。

4 GUI审核界面详解

4.1 工具栏按钮功能

GUI顶部工具栏包含以下按钮，从左到右依次为：

按钮	功能	详细说明
Load Data	加载已有分析结果	从输出目录加载变体群组文件（3_变体群组_待审核.csv），恢复之前的审核进度。如果已有审核记录（审核记录.jsonl），同时恢复已审核群组的状态。
Run Analysis	运行完整分析	弹出对话框选择输入文件或文件夹，然后运行Step 1-4的完整分析流程。分析完成后自动加载结果到审核界面。
Load Global Map	加载全局映射表	加载一个CSV格式的全局映射表文件。加载后，下次运行分析时，已知同义词会被策略0自动预合并，无需再次审核。工具栏显示已加载的映射条目数。
Confirm All & Export	确认全部并导出映射表	将所有群组（包括未审核的）按建议标准词导出为映射表CSV。未审核的群组按算法建议合并。适合审核完大部分群组后快速导出。
Export Mapping	仅导出已审核映射表	只导出已人工审核过的群组的映射表，跳过未审核群组。导出后会询问是否同时更新全局映射表。
Apply & Export Final	应用映射表并导出最终结果	将映射表应用到原始文献数据，生成标准化关键词列表、频次表和共现分析就绪文件。这是最终交付步骤。
Error Analysis	审核错误分析	读取审核记录，按策略统计FP率，聚类错误模式，生成规则修正建议报告。用于迭代优化循环。
Install Deps	安装依赖	一键安装Python依赖包，首次使用时点击。

4.2 审核操作说明

审核界面分为左右两栏：左侧为群组列表，右侧为当前群组的详细信息和操作按钮。

群组列表（左侧）

每个群组显示一行，包含：群组编号、关键词列表、审核状态。状态列显示"待审核"或已审核的操作类型。

审核操作按钮（右侧）

选中一个群组后，右侧显示该群组的所有关键词及其频次，以及以下操作按钮：

按钮	名称	说明
Confirm	确认合并	将群组内所有关键词合并为建议标准词。这是最常用的操作，表示"这些词确实是同义词"。
Keep All	保留全部	不合并任何词，每个词保持独立。用于"这些词看似相似但实际是不同概念"的情况。

按钮	名称	说明
Selective	选择性合并	逐个勾选要合并的词，未勾选的保持独立。用于"3个词中只有2个是同义词"的精细操作。
Auto Confirm	自动确认	一键确认所有建议标准词与频次最高词相同的群组。适合审核后快速处理明显正确的群组。

审核进度自动保存：每审核一个群组，决策自动追加到"审核记录.jsonl"文件。关闭GUI后重新打开，已审核的群组状态会自动恢复，无需从头开始。

4.3 策略来源标识

每个关键词对旁边标注了匹配策略来源，帮助判断可信度：

标签	策略	说明
全局映射	策略0	来自自己审核期刊的映射表，可信度最高，无需再审
归一化	策略1	去除格式差异后完全相同，确定性最高
前后缀	策略2	仅差一个语法后缀（学/法），可信度高
Jaccard	策略3	字符级相似度匹配，需人工确认
编辑距离	策略4	少量字符差异，需仔细确认，FP率最高

5 全局映射表功能

5.1 使用场景

当您需要处理多种期刊（如27种护理学期刊）时，不同期刊的关键词存在大量重叠。如果逐个审核，"循证护理"与"循证护理学"的合并决策需要在每种期刊中重复做出。

全局映射表功能让您只需审核一次，后续期刊自动复用：

5.2 操作流程

第1本期刊（如《当代护士》）：

1. 点击"Run Analysis"运行分析（不加载全局映射）
2. 审核变体群组
3. 点击"Export Mapping"导出映射表
4. 弹窗询问"Update global mapping?", 点击Yes
5. 选择保存位置，命名为 global_mapping.csv

第2本期刊（如《中华护理教育》）：

1. 点击"Load Global Map", 选择上一步保存的 global_mapping.csv
2. 工具栏显示"(N mappings loaded)"
3. 点击"Run Analysis"运行分析
4. 日志显示"策略0: 预合并 N 对已知同义词"——这些群组无需再审
5. 只需审核新出现的变体
6. 审核完成后，"Export Mapping"并更新全局映射表

第3-27本期刊：重复上述流程。随着全局映射表不断积累，每本新期刊需要审核的群组越来越少。

5.3 增量积累机制

全局映射表采用增量更新策略：

- 每次导出映射表时，新确认的映射追加到全局映射表
- 如果同一个变体词在多次审核中有不同标准词，以最新审核为准
- 全局映射表是普通CSV文件，可用Excel打开查看和手动编辑
- CSV格式：两列，第一列"变体"，第二列"标准词"

标准词规则：当群组中存在"XX"和"XX学"时，工具自动选择"XX学"作为标准词。例如"老年护理"和"老年护理学"合并后，标准词为"老年护理学"。这确保了跨期刊的一致性。

6 迭代优化循环

工具支持"部分审核 - 错误分析 - 规则修正 - 重新分析"的迭代优化循环，逐步提高自动合并的准确率。

6.1 Error Analysis

审核一定数量的群组后（建议50-100组），点击**Error Analysis**按钮，工具生成错误分析报告，包含：

报告内容	说明
各策略FP率	按策略统计误匹配率，定位问题策略。例如S4 FP率50%说明编辑距离策略需要收紧。
误匹配示例	每个策略列出典型FP案例，帮助理解错误模式。
错误模式聚类	将FP案例分为"共享前缀但分歧""不同器官/部位"等类别。
规则修正建议	自动生成针对性建议，如"降低edit_ratio""增加语义验证"等。

6.2 规则修正流程

将Error Analysis报告反馈给开发者，开发者根据报告修正规则参数（如扩展关键字符集、调整阈值等），发布新版本。您用新版本重新运行分析，审核后再次Error Analysis，循环迭代直到FP率满意。

典型迭代效果（基于实际数据）：

版本	整体FP	S2 FP	S3 FP	S4 FP	S5 FP	关键改动
v2.0	50.2%	48.6%	28.6%	45.3%	-	基线版本
v2.1	37.4%	34.4%	22.7%	44.4%	-	清空前缀、新增语义分歧检测
v2.3	37.7%	9.7%	0.0%	50.0%	-	禁用S5增强、扩展关键字符集
v2.4	<15%	<3%	0.0%	<20%	-	扩展关键字符+内容词对+修复S2

7 输出文件详解

所有输出文件保存在指定的输出目录中。按生成顺序排列如下：

7.1 Step 3 输出（原始数据）

文件名	内容	列说明	用途
1_原始关键词列表.csv	每条文献记录的关键词明细	记录ID, 标题, 关键词（分号分隔）	查看每篇文献的原始关键词
2_关键词频次表.csv	所有唯一关键词的出现频次	关键词, 频次, 累积频次, 累积百分比	了解关键词分布, 确定高频词

7.2 Step 4 输出（变体检测结果）

文件名	内容	列说明	用途
3_变体群组_待审核.csv	所有变体群组及建议标准词	群组ID, 关键词, 频次, 建议标准词, 是否建议标准词, 匹配策略	GUI审核界面的数据源
3_配对策略溯源.csv	每对匹配的策略来源	词A, 词B, 策略编号, 策略名称	定位问题策略, Error Analysis的数据源

7.3 Step 5 输出（审核记录）

文件名	内容	列说明	用途
审核记录.jsonl	人工审核决策日志	每行一条JSON: 群组ID, 操作类型, 标准词, 时间戳, 工具版本	断点续审、Error Analysis的数据源

7.4 Step 6 输出（标准化结果）

文件名	内容	列说明	用途
映射表_已审核.csv	变体到标准词的映射	变体, 标准词	记录合并决策, 可复用于其他期刊
5_标准化关键词列表.csv	每条文献的标准化关键词	记录ID, 标题, 原始关键词, 标准化关键词	查看每篇文献的标准化结果
5_关键词频次表.csv	标准化后的关键词频次	关键词, 频次, 累积频次, 累积百分比	标准化后的频次统计
6_共现分析就绪.csv	共现分析输入格式	每行一条记录, 关键词用分号分隔	直接导入共现分析工具

7.5 Error Analysis 输出

文件名	内容	列说明	用途
审核错误分析报告.txt	错误分析报告	各策略FP率、误匹配示例、 错误模式聚类、规则修正建议	指导规则修正方向

7.6 全局映射表文件

文件名	内容	列说明	用途
global_mapping.csv	跨期刊共享的映射表	变体, 标准词	多期刊批量处理时复用 已审核结果

8 命令行使用

除GUI外，工具也支持命令行操作，适合批量处理和脚本集成。

8.1 完整分析

```
python keyword_cleaner.py -i 数据目录/ -o 输出目录/
```

参数说明：

-i / --input: 输入XML文件或目录路径（必需）

-o / --output: 输出目录（默认：输入路径/output）

8.2 使用全局映射表

```
python keyword_cleaner.py -i 数据目录/ -o 输出目录/ -g global_mapping.csv
```

-g / --global-mapping: 全局映射表CSV文件路径

8.3 应用已有映射表

```
python keyword_cleaner.py -i 数据目录/ -m 映射表.csv -o 输出目录/
```

-m / --mapping: 映射表CSV文件路径（跳过变体检测，直接应用）

8.4 仅频次统计

```
python keyword_cleaner.py -i 数据目录/ -o 输出目录/ --freq-only
```

8.5 调整灵敏度

```
python keyword_cleaner.py -i 数据目录/ -o 输出目录/ --sensitivity 1
```

灵敏度选项：1=宽松（多合并，可能多误匹配）、2=默认、3=严格（少合并，可能漏检）

8.6 错误分析

```
python review_analyzer.py 输出目录/
```

独立运行错误分析脚本，读取审核记录生成报告。

8.7 训练数据导出

```
python review_analyzer.py 输出目录/ --export-training
```

导出配对标注数据（CSV+JSON格式），供语义相似度模型训练使用。

9 常见问题

Q1: 万方XML文件没有扩展名怎么办?

工具自动检测文件内容（读取前500字节判断是否为XML），不依赖扩展名。直接选择文件或放入文件夹即可。

Q2: 审核到一半关闭了GUI，进度会丢失吗?

不会。每审核一个群组，决策自动保存到"审核记录.jsonl"。重新打开GUI并加载数据，已审核的群组会自动恢复状态。

Q3: 全局映射表加载后，之前已审核的群组会重复出现吗?

不会。策略0预合并的群组标记为"全局映射"来源，与策略1-4检测的群组互不冲突。如果一个词对已被全局映射合并，后续策略不会重复检测。

Q4: XX和XX学应该合并吗?

按照工具的默认规则，"XX"和"XX学"被视为同义词，标准词统一取"XX学"。例如"老年护理"合并为"老年护理学"。如果您认为某个特定情况不应合并，可以在审核时点击"Keep All"拒绝。

Q5: 为什么有些明显相似的词没有被检测到?

可能原因：(1) 语义分歧检测拦截了——差异字符在关键字符集中；(2) 灵敏度太低——尝试--sensitivity 1；(3) 长度差异太大——当前限制长度比不超过1.3。

Q6: Error Analysis报告的FP率很高怎么办?

将报告反馈给开发者。开发者会根据FP模式修正规则参数（扩展关键字符集、调整阈值等），发布新版本。您用新版本重新运行分析即可。这是正常的迭代优化过程。

Q7: 可以手动编辑全局映射表吗?

可以。全局映射表是普通CSV文件（UTF-8编码），可用Excel或文本编辑器打开。格式为两列：变体、标准词。手动编辑后保存为CSV格式即可。

Q8: 27种期刊应该按什么顺序处理?

建议从文献量最大的期刊开始，这样全局映射表积累最快。后续期刊中需要人工审核的群组会越来越少。